

Python数据分析学习路线

从入门到进阶的完整课程大纲

涵盖：数据处理与可视化 | 统计学基础 | 机器学习入门 | 数据工程与工具链

2026 版

目录

模块一：Python 编程基础与环境搭建

- 1.1 开发环境配置
- 1.2 Python 核心语法
- 1.3 面向对象编程
- 1.4 Python 进阶特性

模块二：NumPy 科学计算

- 2.1 ndarray 核心概念
- 2.2 数组运算
- 2.3 高级应用

模块三：Pandas 数据处理

- 3.1 数据结构基础
- 3.2 数据读取与写入
- 3.3 数据清洗与预处理
- 3.4 数据筛选与变换
- 3.5 分组聚合
- 3.6 时序数据处理

模块四：数据可视化

- 4.1 Matplotlib 基础
- 4.2 Seaborn 统计可视化
- 4.3 交互式可视化
- 4.4 高级可视化技巧

模块五：统计学基础

- 5.1 描述统计
- 5.2 概率论基础
- 5.3 推断统计
- 5.4 回归分析

模块六：机器学习入门

- 6.1 机器学习概论
- 6.2 监督学习算法
- 6.3 无监督学习算法
- 6.4 特征工程

6.5 模型部署入门

模块七：数据工程与工具链

- 7.1 SQL 与数据库
- 7.2 大数据处理工具
- 7.3 数据工程流水线
- 7.4 版本控制与协作
- 7.5 云计算与部署

模块八：综合项目实战

- 8.1 项目一：电商用户行为分析
- 8.2 项目二：金融风控与信用评分
- 8.3 项目三：社交媒体舆情分析
- 8.4 项目四：推荐系统入门
- 8.5 学习资源与进阶方向

模块一：Python 编程基础与环境搭建

1.1 开发环境配置

- Python 安装与版本管理 (pyenv / Anaconda / Miniconda)
- IDE 选择与配置 (VS Code / PyCharm / JupyterLab)
- 虚拟环境管理 (venv / conda env)
- 包管理工具 (pip / conda / uv)

1.2 Python 核心语法

- 数据类型与数据结构 (list / tuple / dict / set)
- 控制流 (if / for / while / comprehensions)
- 函数定义与高阶函数 (lambda / map / filter / functools)
- 模块与包 (import 机制 / __init__.py / 相对导入)

1.3 面向对象编程

- 类与对象 (class / __init__ / self)
- 继承、多态、封装
- 魔术方法 (__str__ / __repr__ / __len__ / __getitem__)
- 数据类 (dataclasses / attrs)

1.4 Python 进阶特性

- 迭代器与生成器
 - 装饰器
 - 上下文管理器 (with 语句)
 - 类型注解 (Type Hints)
 - 异常处理与日志 (logging)
-

模块二：NumPy 科学计算

2.1 ndarray 核心概念

- 数组创建 (array / arange / linspace / zeros / ones)
- 数组属性 (shape / dtype / ndim / size)
- 索引与切片 (基本索引 / 布尔索引 / 花式索引)

2.2 数组运算

- 向量化运算与广播机制 (Broadcasting)
- 数学运算 (sum / mean / std / min / max / argmax)
- 线性代数 (dot / matmul / det / inv / eig)
- 随机数生成 (random 模块 / seed / 分布)

2.3 高级应用

- 数组重塑 (reshape / transpose / flatten)
 - 拼接与分割 (concatenate / stack / split)
 - 文件 I/O (loadtxt / savetxt / npy / npz)
 - 性能优化 (向量化 vs 循环 / 内存布局 C-order vs F-order)
-

模块三：Pandas 数据处理

3.1 数据结构基础

- Series 创建与操作
- DataFrame 创建 (dict / list / numpy array / 读取文件)
- 索引体系 (Index / MultiIndex / set_index / reset_index)

3.2 数据读取与写入

- CSV / Excel / JSON / Parquet 读写
- SQL 数据库交互 (SQLAlchemy / read_sql)
- HTML 表格解析 / 剪贴板读取

3.3 数据清洗与预处理

- 缺失值处理 (isna / fillna / dropna / interpolate)
- 重复值处理 (duplicated / drop_duplicates)
- 数据类型转换 (astype / to_datetime / to_numeric)
- 字符串处理 (str 访问器 / 正则表达式)

3.4 数据筛选与变换

- 条件筛选 (布尔索引 / query / loc / iloc)
- 排序 (sort_values / sort_index)
- 列操作 (assign / apply / map / pipe)
- 数据合并 (merge / join / concat / combine_first)

3.5 分组聚合

- groupby 基础与高级用法
- 聚合函数 (agg / transform / apply)
- 透视表与交叉表 (pivot_table / crosstab)
- 窗口函数 (rolling / expanding / ewm)

3.6 时序数据处理

- DatetimeIndex 与时间序列
- 重采样 (resample / asfreq)
- 时区处理 (tz_localize / tz_convert)
- 时间偏移与周期 (Period / DateOffset)

模块四：数据可视化

4.1 Matplotlib 基础

- Figure 与 Axes 体系
- 折线图 / 散点图 / 柱状图 / 直方图 / 饼图
- 图表定制（标题 / 标签 / 图例 / 颜色 / 样式）
- 子图布局（subplot / subplots / GridSpec）

4.2 Seaborn 统计可视化

- 分布图（distplot / kdeplot / histplot）
- 关系图（scatterplot / lineplot / relplot）
- 分类图（barplot / boxplot / violinplot / swarmplot）
- 热力图与聚类图（heatmap / clustermap）
- 主题与调色板（set_theme / palette）

4.3 交互式可视化

- Plotly 基础（Figure / Trace / Layout）
- 交互式图表（go.Scatter / go.Bar / go.Pie）
- Plotly Express 快速绑定
- Dash / Streamlit 数据应用搭建入门

4.4 高级可视化技巧

- 地理数据可视化（Folium / GeoPandas）
- 网络图可视化（NetworkX + matplotlib）
- 大规模数据可视化（Datashader / Vaex）
- 可视化最佳实践与配色理论

模块五：统计学基础

5.1 描述统计

- 集中趋势（均值 / 中位数 / 众数）
- 离散程度（方差 / 标准差 / 极差 / IQR）
- 分布形态（偏度 / 峰度）
- 相关性分析（Pearson / Spearman / Kendall）

5.2 概率论基础

- 随机变量与概率分布
- 常见离散分布（二项 / 泊松 / 几何）
- 常见连续分布（正态 / 指数 / 均匀 / 卡方）
- 大数定律与中心极限定理
- Python 实现（scipy.stats）

5.3 推断统计

- 参数估计（点估计 / 区间估计 / 置信区间）
- 假设检验基础（原假设 / 备择假设 / p 值 / 显著性水平）
- t 检验（单样本 / 独立样本 / 配对样本）
- 卡方检验（拟合优度 / 独立性检验）
- ANOVA 方差分析（单因素 / 多因素）
- 非参数检验（Mann-Whitney U / Kruskal-Wallis）

5.4 回归分析

- 线性回归（OLS / statsmodels）
- 多元回归与变量选择
- 逻辑回归
- 回归诊断（残差分析 / 多重共线性 / 异方差检验）

模块六：机器学习入门

6.1 机器学习概论

- 监督学习 / 无监督学习 / 强化学习
- 训练集 / 验证集 / 测试集划分
- 交叉验证（KFold / StratifiedKFold）
- 评估指标（准确率 / 精确率 / 召回率 / F1 / AUC-ROC）
- 过拟合与欠拟合 / 正则化（L1 / L2）

6.2 监督学习算法

- 线性回归与多项式回归
- 逻辑回归
- 决策树（CART / 剪枝策略）
- 随机森林与 Bagging

- 梯度提升 (XGBoost / LightGBM / CatBoost)
- SVM 支持向量机
- KNN K近邻

6.3 无监督学习算法

- K-Means 聚类
- 层次聚类
- DBSCAN 密度聚类
- PCA 主成分分析
- t-SNE / UMAP 降维可视化

6.4 特征工程

- 特征提取 (数值 / 类别 / 文本 / 时间特征)
- 特征编码 (One-Hot / Label Encoding / Target Encoding)
- 特征缩放 (StandardScaler / MinMaxScaler / RobustScaler)
- 特征选择 (过滤法 / 包裹法 / 嵌入法)
- Pipeline 构建 (sklearn.pipeline)

6.5 模型部署入门

- 模型持久化 (pickle / joblib)
- REST API 部署 (FastAPI / Flask)
- ONNX 模型导出

模块七：数据工程与工具链

7.1 SQL 与数据库

- SQL 基础语法 (SELECT / JOIN / GROUP BY / 子查询)
- 窗口函数 (ROW_NUMBER / RANK / LAG / LEAD)
- 查询优化 (索引 / 执行计划 / EXPLAIN)
- Python 数据库交互 (SQLAlchemy / psycopg2 / sqlite3)

7.2 大数据处理工具

- Polars 高性能 DataFrame (LazyFrame / 惰性求值)
- DuckDB 嵌入式分析数据库

- Apache Spark 基础 (PySpark / RDD / DataFrame)
- 数据格式进阶 (Parquet / Arrow / ORC)

7.3 数据工程流水线

- ETL 概念与设计模式
- Apache Airflow 工作流编排
- dbt 数据转换
- 数据质量监控 (Great Expectations)

7.4 版本控制与协作

- Git 基础 (commit / branch / merge / PR)
- DVC 数据版本控制
- MLflow 实验追踪与模型注册
- Jupyter Notebook 最佳实践

7.5 云计算与部署

- Docker 容器化基础
- 云平台概览 (AWS / GCP / 阿里云)
- 数据仓库概念 (BigQuery / Redshift / Snowflake)

模块八：综合项目实战

8.1 项目一：电商用户行为分析

- 数据采集与清洗
- 用户画像构建 (RFM 模型)
- 购买转化漏斗分析
- 可视化仪表盘搭建

8.2 项目二：金融风控与信用评分

- 特征工程 (WOE / IV 特征筛选)
- 逻辑回归 / XGBoost 违约预测
- 模型评估 (KS 值 / ROC-AUC / Gini 系数)
- 评分卡模型构建

8.3 项目三：社交媒体舆情分析

- 数据采集（API / 爬虫）
- 中文文本预处理（jieba 分词 / 去停用词）
- 情感分析（TF-IDF / 词云 / 主题模型 LDA）
- 舆情趋势可视化

8.4 项目四：推荐系统入门

- 协同过滤（User-CF / Item-CF）
- 基于内容的推荐
- 矩阵分解（SVD / ALS）
- 评估指标（Precision@K / NDCG / 覆盖率）

8.5 学习资源与进阶方向

- 推荐书籍与在线课程
- Kaggle 竞赛指南
- 技术社区与博客
- 认证考试（CDA / PMP / AWS Data Analytics）